






Modélisation des notations YUKA

Econométrie
qualitative

Ibrahima Fa Lô, Baptiste Comby, Fanny Lattard


Introduction



- + de 40 millions d'utilisateurs **Yuka** $\Rightarrow$ Est-ce que ce produit est bon pour ma santé ?
 $\Rightarrow$ Pastilles de couleur : de mauvais à excellent
- Algorithme complexe : données nutritionnelles brutes $\rightarrow$ décision d'achat.

Comment ces différents composants s'articulent-ils réellement pour déterminer la note finale ?

Objectif : "rétro-concevoir" l'algorithme Yuka avec un jeu de données de produits



PLAN DE LA PRÉSENTATION



ANALYSE DONNÉES

Distribution des scores
Yuka et variables
explicatives
nutritionnelles.



MÉTHODOLOGIE

Spécification du modèle Logit
Ordonné et variable latente.




VALIDATION

Tests statistiques,
courbe ROC et matrice
de confusion.



RÉSULTATS

Coefficients, Odds
Ratios et effets
marginaux moyens
(AME).



01

**Analyse
exploratoire**



COMPRENDRE LE SCORE


L'application Yuka décode les étiquettes alimentaires pour attribuer une note sur 100, segmentée en 4 classes qualitatives.

Échantillon : 1 000 produits alimentaires.

Inputs : Calories, sucres, sel, graisses, fibres, protéines, additifs.

Bonus : Statut Bio et niveau de transformation (NOVA).

Répartition des scores Yuka



PROFIL NUTRITIONNEL MOYEN


Valeurs moyennes pour **100g** de produit :

Nutriment	Mauvais	Médiocre	Bon	Excellent	P_value ANOVA
calories_100g	322.775	245.078	187.263	115.777	< 0.001
sucres_100g	16.417	12.220	10.589	6.927	< 0.001
sel_100g	0.968	0.863	0.715	0.479	< 0.001
fibres_100g	2.357	3.297	3.364	3.724	< 0.001
proteines_100g	6.118	7.337	7.952	8.971	< 0.001
graisses_saturees_100g	4.876	4.213	3.396	2.719	< 0.001
nb_additifs	2.652	1.297	0.926	0.857	< 0.001


L'augmentation des nutriments "négatifs" (sucre, sel, calories) suit strictement la dégradation de la note.

INTERDÉPENDANCE DES VARIABLES

Matrice de corrélation



La matrice de corrélation révèle qu'il n'existe aucune colinéarités parmi les variables du modèle



IMPACT DU BIO ET DE L'ULTRA-TRANSFORMATION



CERTIFICATION BIO

82% des produits classés "Excellent" sont certifiés Bio.

Chi²: Significatif ($p < 0.001$)




ULTRA-TRANSFORMATION


Les produits NOVA 4 représentent 75% de la classe "Mauvais".


Liaison Négative Forte

Répartition Bio




Répartition Ultra-Transfo






IMPACT DU BIO ET DE L'ULTRA-TRANSFORMATION

Répartition des scores Yuka pour produit bio ou non



Répartition des scores Yuka par degré de transformation



CERTIFICATION BIO

Fait basculer un produit d'une catégorie "Médiocre" à "Bon"

Corrélation positive



ULTRA-TRANSFORMATION

produits "Mauvais" sont des produits dits "ultra-transformés"


Liaison Négative Forte






02

Methodologie



CHOIX DU MODELE




Variable latente = "score de santé absolu"

$$Y_i^* = X_i\beta + \varepsilon_i$$


$X_i \Rightarrow$ variables explicatives (sucre, sel, fibres, label bio, etc.).

B représente les coefficients à estimer pour chaque variable.

$E_i \Rightarrow$ terme d'erreur $\Rightarrow$ suit une distribution logistique standard.



CHOIX DU MODELE



Les seuils critiques (α) et la classification

Le produit est classé en comparant son score latent Y_i^* à ces seuils :


- **Mauvais** ($Y = 1$) si $Y_i^* \leq \alpha_1$
- **Médiocre** ($Y = 2$) si $\alpha_1 \leq Y_i^* \leq \alpha_2$
- **Bon** ($Y = 3$) si $\alpha_2 \leq Y_i^* \leq \alpha_3$
- **Excellent** ($Y = 4$) si $Y_i^* > \alpha_3$



$$P(Y \leq j) = \frac{1}{1 + e^{-(\kappa_j - \sum \beta_i X_i)}}$$



Calcule la probabilité cumulée d'appartenir à une catégorie j ou inférieure



SPÉCIFICATION DU MODÈLE


MODÈLE COMPLET (IDÉAL)

$$Y_1 = \beta_1 \text{ cal} + \beta_2 \text{ suc} + \beta_3 \text{ sel} + \beta_4 \text{ gras} + \beta_5 \text{ add} + \beta_6 \text{ fib} + \beta_7 + \beta_8 + \beta_9 + \varepsilon_i$$

MODÈLE TEST YUKA (SIMPLIFIÉ)

$$Y_i^{**} = \beta_1 \text{ suc} + \beta_2 \text{ sel} + \beta_3 \text{ gras} + \varepsilon_i$$

Modèle Statistique	df	AIC	BIC	Pseudo R ²
Modèle Complet Optimal	12	355	414	0.875
Modèle Réduit	11	976	1030	0.641
Modèle Test Yuka	6	2332	2362	0.126



L'hypothèse des pentes parallèles

TEST DE BRANT

Même effet des variables quel que soit le seuil de score franchi

H_0 = coefs sont les mêmes pour chaque catégorie de note


Yuka = pentes parallèles

$P > 0,05 \rightarrow$ l'hypothèse est respectée

Le test Omnibus $p = 0,35$


notre modèle est statistiquement valide





03

Validation




Variable	Coeff. β	Std. Error	t-value (z)	p-value	Significativité
calories_100g	-0.07743	0.0021	-4.24	< 0.001	***
sucres_100g	-0.73058	0.0087	-4.74	< 0.001	***
sel_100g	-9.24930	0.0521	-7.38	< 0.001	***
graisses_saturées_100g	-2.05439	0.0193	-3.54	< 0.001	***
fibres_100g	+2.92815	0.0267	+7.22	< 0.001	***
protéines_100g	+0.94544	0.0142	+2.21	< 0.001	***
nb_additifs	-2.92815	0.0348	-6.36	< 0.001	***
bio1 (Label Bio)	+7.63229	0.1204	+7.34	< 0.001	***
ultra_transformé1	-7.60035	0.1587	-7.86	< 0.001	***

MATRICE DE CONFUSION/ AUC-ROC

	Mauv.	Méd.	Bon	Excel.
Mauvais	356	11	0	0
Médiocre	12	244	13	0
Bon	0	14	209	8
Excellent	0	0	8	125

Courbe ROC — Excellent (AUC = 0.998)



0.99
AUC (EXCELLENT)


93%
ACCURACY GLOBALE

0.88
PSEUDO-R² MCFADDEN




04

Résultats



ANALYSE DES ODDS RATIOS (RAPPORT DES CHANCES)


Lecture : Un OR > 1 indique un impact positif sur la probabilité d'une meilleure note Yuka.



L'effet massif du BIO : Le label bio multiplie de façon exceptionnelle les chances d'accéder aux classes supérieures, reflétant sa place centrale dans l'algorithme Yuka.

Probabilités des scores selon nutriment


Probabilité des scores selon le taux de sucre



Sucre

DÉCLASSEUR IMMÉDIAT

Probabilité des scores selon le taux de protéines



Protéines

BONUS POUR L'ALGORITHME

HIÉRARCHIE DES EFFETS MARGINAUX



LEVIER MAJEUR

+7.63

Coefficient BIO

Plus fort impact positif du modèle.



PÉNALITÉ CRITIQUE

-9.25

Coefficient SEL

Le sel est le nutriment le plus dégradant pour la note.



TRANSFORMATION

-7.60

Ultra-transformé

Effet négatif comparable à l'absence de label bio.

NUTRIMENTS DE BONIFICATION

- **Fibres (+2.06)** : Impact positif très marqué sur le score final.
- **Protéines (+0.94)** : Contribue favorablement à la notation.

NUTRIMENTS DE PÉNALISATION

- **Additifs (-2.93)** : Chaque additif réduit significativement la probabilité d'une bonne note.
- **Sucres (-0.73)** : Impact négatif persistant et significatif.

CONCLUSION & SYNTHÈSE

✓ VALIDITÉ DU MODÈLE

Le **Logit Ordonné** est confirmé comme le cadre optimal (Test de Brant validé, $p=0.345$) pour traiter l'aspect ordinal des notations Yuka sans biais de linéarité.

🔧 POUVOIR PRÉDICTIF


Avec une **Accuracy de 93%** et un **AUC de 0.99**, le modèle démontre une excellente capacité à identifier les déterminants de la qualité nutritionnelle.

⚠️ LE POIDS DE L'INDUSTRIE

L'**ultra-transformation** et le sel reste des facteurs très pénalisants

🌱 LEVIERS DE VALORISATION

La **certification Bio** et l'apport en **fibres** constituent les leviers majeurs de bonification du score pour les fabricants.



Merci!

Etudiants : **Ibrahima Fa Lô, Baptiste Comby, Fanny Lattard**

